Lead Scoring para Prospecting B2B

Sistema de Priorización de Leads con Machine Learning

Priscila Calcerano · Vinicius Santini · Adriana Caballero

Máster en Data Science & IA

Nuclio Digital School — Barcelona

Tutora: Raquel Revilla

Marzo 2026

Índice

Índice 2
1. Introducción 3
2. Justificación y Contextualización 4
3. Objetivos 5
Objetivo general 5
Objetivos específicos 5
4. Metodología empleada 6
4.0 Estructura del proyecto 6
4.1 Fase 1: Carga y preparación de datos (NB01) 7
Variable objetivo 7
Limpieza y filtrado 7
4.2 Fase 2: Análisis exploratorio (NB02) 8
Distribución de la variable objetivo 8
Hallazgos principales 8
Validación estadística 8
4.3 Fase 3: Ingeniería de features (NB03) 9
Gestión de valores nulos y outliers 9
Orígenes de las features 10
Features de ingeniería propia (fe_) 10
Features de enriquecimiento externo (ext_) 11
Features de NLP (nlp_) 11
Features de tech fit por producto (fe_tech_fit_) 11
Aplicación al pool de no contactados 11
4.4 Fase 4: Modelado predictivo (NB04) 12
Selección de features para el modelo 12
Elección de métricas 12
Competición de modelos 12
Tuneo de hiperparámetros con Optuna 13
Rendimiento final del modelo 13
Análisis SHAP: qué aprendió el modelo 13

Impacto del proceso de cualificación IA 14
Target alternativo: respuestas positivas 14
Segmentación con K-Means 14
4.5 Fase 5: MLOps — Infraestructura de producción (NB05) 14
Dos entornos: demo y producción 15
Demo: Streamlit Cloud 15
Arquitectura de producción 15
Pipelines de producción 15
DAG 1: Scoring semanal 16
DAG 2: Monitoring mensual 16
Validación del entorno de producción 16
5. Resultados y Conclusiones 16
Resultados principales 16
Hallazgos de negocio 17
Contribución técnica 17
Limitaciones 17
Trabajo futuro 18
Conclusión 18
6. Referencias / Bibliografía 18
Artículos académicos 18
Librerías y frameworks 18
Plataformas y herramientas 19

1. Introducción

Este proyecto aborda un problema real de la empresa Raona, Microsoft Gold Partner en Barcelona especializada en soluciones digitales. Su equipo comercial contacta miles de prospectos B2B a través de LinkedIn y email mediante campañas de outreach gestionadas con la herramienta Enginy. De los casi 6,000 contactos del dataset, solo el 14% responde.

El objetivo principal es construir un sistema de lead scoring que permita al equipo comercial priorizar sus esfuerzos: contactar primero a los prospectos con mayor probabilidad de respuesta. El sistema combina datos del perfil de LinkedIn, informes generados por IA (Enginy), procesamiento de lenguaje natural sobre textos generados por IA y señales externas del stack tecnológico de cada empresa.

El proyecto se estructura en cinco fases: carga y limpieza de datos, análisis exploratorio, ingeniería de features (incluyendo NLP con Sentence-BERT y BERTopic), modelado predictivo (LightGBM tuneado con Optuna) y despliegue MLOps (API REST con FastAPI, orquestación con Airflow y monitorización de drift con PSI).

El modelo resultante alcanza un Precision@100 del 39% — casi tres veces la tasa base del 14% — y un lift de 2.6x en el top 10% de leads. Además del modelo, el proyecto entrega una demo interactiva en Streamlit Cloud y una arquitectura de producción completa con Docker, lista para desplegarse.

La memoria documenta el proceso completo, desde la definición del problema hasta la puesta en producción, con el detalle técnico de cada decisión tomada.

2. Justificación y Contextualización

En el mercado B2B, el proceso de prospección comercial es intensivo en tiempo y recursos. Un equipo de ventas típico dedica gran parte de su jornada a contactar prospectos que nunca responderán, mientras leads con alto potencial quedan sin atender. Este problema se amplifica cuando el volumen de contactos crece y la selección se basa en intuición o criterios genéricos.

Raona es una consultora tecnológica con sede en Barcelona, Microsoft Gold Partner, que ofrece soluciones de transformación digital a empresas. Su equipo comercial utiliza Enginy (anteriormente Genesy AI), una plataforma de ventas B2B basada en IA que automatiza el proceso de prospección multicanal. Enginy combina enriquecimiento de datos a través de más de 30 fuentes con investigación mediante IA para obtener contexto detallado de cada prospecto y empresa. La plataforma automatiza desde la extracción de datos de LinkedIn hasta el envío de mensajes personalizados, generando informes de cualificación con IA antes del primer contacto.

A pesar de este enriquecimiento, la tasa de respuesta global en las campañas de Raona es del 14%. Esto significa que de cada 100 contactos, 86 no responden. El coste de oportunidad es significativo: el equipo comercial invierte el mismo esfuerzo en un lead que responderá que en uno que no.

La pregunta que motiva este proyecto es: **¿se puede predecir qué contactos tienen mayor probabilidad de responder, y utilizar esa predicción para priorizar el outreach?**

El lead scoring — la asignación de una puntuación numérica a cada prospecto según su probabilidad de conversión — es una técnica cada vez más adoptada en entornos B2B. Un estudio reciente publicado en Frontiers in Artificial Intelligence (Martínez-Salas et al., 2025) demuestra que los modelos de machine learning basados en gradient boosting superan significativamente a los métodos heurísticos tradicionales en la priorización de leads B2B, permitiendo a los equipos comerciales optimizar su tiempo centrándose en los prospectos con mayor probabilidad de conversión. Sin embargo, la mayoría de estas implementaciones trabajan con datos de CRM internos. La combinación de datos de LinkedIn con enriquecimiento generado por IA, como en el caso de Enginy, representa un enfoque menos explorado que este proyecto aborda con datos reales de producción.

El interés personal del equipo se sitúa en la intersección entre data science y negocio: construir no solo un modelo predictivo, sino un sistema completo que el equipo comercial de Raona pueda usar en su día a día para tomar mejores decisiones de prospección.

3. Objetivos

El proyecto persigue un objetivo general y varios objetivos específicos que cubren desde el análisis de datos hasta la puesta en producción del sistema.

Objetivo general

Desarrollar un sistema de lead scoring basado en machine learning que permita al equipo comercial de Raona priorizar sus esfuerzos de prospección B2B, contactando primero a los leads con mayor probabilidad de respuesta.

Objetivos específicos

1. Explorar y comprender los datos — Analizar el dataset de casi 6,000 contactos para identificar qué variables distinguen a los contactos que responden de los que no, descubriendo patrones de comportamiento por seniority, tamaño de empresa, canal de contacto y timing.

2. Construir un pipeline de feature engineering robusto — Transformar los datos brutos en 39 features accionables combinando cuatro orígenes: datos de LinkedIn, enriquecimiento externo del stack tecnológico, variables de ingeniería propia y features derivadas de NLP (embeddings con Sentence-BERT, topic modeling con BERTopic y extracción de señales de urgencia).

3. Entrenar y evaluar un modelo predictivo — Comparar múltiples algoritmos de clasificación (Logistic Regression, Random Forest, LightGBM, XGBoost), seleccionar el mejor y tunearlo con Optuna, priorizando métricas de ranking (PR-AUC, Precision@k, Lift) sobre métricas de clasificación binaria.

4. Segmentar los prospectos — Aplicar clustering (K-Means) para identificar perfiles diferenciados de prospectos y adaptar la estrategia de outreach a cada segmento.

5. Diseñar y desplegar una arquitectura de producción — Construir un sistema completo con API REST (FastAPI), orquestación de pipelines (Airflow), monitorización de drift (PSI) y reentrenamiento condicional, desplegado en contenedores Docker.

6. Crear una demo interactiva — Desplegar una aplicación en Streamlit Cloud con dashboard de KPIs, scoring individual y scoring en lote, accesible para el equipo comercial sin necesidad de conocimientos técnicos.

4. Metodología empleada

El proyecto sigue un enfoque teórico-práctico estructurado en cinco fases secuenciales, cada una documentada en un notebook independiente. Las fases reflejan el ciclo completo de un proyecto de data science aplicado: desde la comprensión de los datos hasta el despliegue en producción.

Fase	Notebook	Descripción
1	01_data_loading	Carga, limpieza y definición de la variable objetivo
2	02_eda	Análisis exploratorio y perfilado estadístico
3	03_feature_engineering	Ingeniería de features, NLP y enriquecimiento externo
4	04_models	Modelado predictivo, segmentación y análisis SHAP
5	05_mlops	Infraestructura de producción y despliegue

4.0 Estructura del proyecto

```
TFM_deliverables/
├── app/
│   ├── api.py                  # API REST (FastAPI)
│   ├── streamlit_app.py        # Demo interactiva (Streamlit Cloud)
│   ├── Dockerfile              # Container API
│   ├── Dockerfile.airflow      # Container Airflow
│   ├── docker-compose.yml      # Orquestación (6 servicios)
│   ├── requirements-api.txt    # Dependencias API (producción)
│   ├── requirements.txt        # Dependencias Streamlit (demo)
│   ├── models/                 # Artefactos del modelo (.pkl)
│   ├── dags/                   # DAGs de Airflow (scoring + monitoring)
│   └── pipelines/              # Módulos Python (ingest, transform, score...)
├── notebooks/
│   ├── 01_data_loading.ipynb
│   ├── 02_eda.ipynb
│   ├── 03_feature_engineering.ipynb
│   ├── 04_models.ipynb
│   └── 05_mlops.ipynb
├── report/
│   ├── index.html              # Data Story
│   └── nb01-nb05 HTML exports  # Notebooks exportados con outputs
└── _working/
```

```
├── data/              # Datasets intermedios (parquet)
└── mlruns/            # Registro de experimentos MLflow
```

Directorio	Contenido
app/	Todo lo necesario para desplegar el sistema: API, demo Streamlit, Dockerfiles, orquestación Airflow, artefactos del modelo y pipelines de datos
notebooks/	Los cinco notebooks que documentan cada fase del proyecto, desde la carga de datos hasta el despliegue
report/	Data Story (index.html) y las exportaciones HTML de los notebooks con todos los outputs y visualizaciones
_working/	Directorio de trabajo con datasets intermedios en formato parquet y el registro de experimentos MLflow. No forma parte del entregable final

Repositorio GitHub: https://github.com/acaballito/raona-lead-scoring
Demo interactiva: https://raona-lead-scoring.streamlit.app

4.1 Fase 1: Carga y preparación de datos (NB01)

El dataset original proviene de la exportación de campañas de outreach B2B de Raona a través de Enginy. Contiene registros de 5,987 contactos con información de perfil de LinkedIn (cargo, antigüedad, empresa, sector, conexiones), datos de la empresa (tamaño, año de fundación, crecimiento de plantilla, tecnologías utilizadas) y campos generados por IA (informes de empresa, informes de contacto, cualificación FIT, seniority, departamento y señales de momentum).

Variable objetivo

Se definieron dos variables objetivo a partir del campo Campaign engagement status:

target_replied (variable principal): vale 1 si el contacto respondió al outreach, independientemente del contenido de la respuesta. Tasa positiva: 14.0% (841 de 5,987).

target_positive (variable alternativa): vale 1 solo si la respuesta fue positiva, excluyendo respuestas negativas ("Not Interested", "Wrong Person"). Se evaluó en NB04 como target alternativo.

La decisión de usar target_replied como variable principal se basa en que cualquier respuesta — incluso negativa — genera valor comercial: un "no me interesa ahora" puede convertirse en un follow-up futuro, y un "no soy la persona adecuada" puede derivar en un referral interno.

Limpieza y filtrado

El dataset se filtró para conservar únicamente los contactos que recibieron al menos un mensaje (excluyendo conexiones aceptadas sin mensaje posterior). Se eliminaron también registros con Microsoft? = -1 (error de clasificación) y FIT = NO (contactos descartados por el proceso de cualificación).

Tras la limpieza, se separó el dataset en dos grupos:

Contactos contactados (5,987 filas, 43 columnas): dataset de modelado con variable objetivo conocida. Las 43 columnas incluyen datos originales de LinkedIn, campos generados por IA y variables auxiliares. En la Fase 3, el feature engineering ampliará el dataset a 70 columnas (nuevas variables derivadas, NLP, enriquecimiento externo), de las cuales se seleccionarán las 39 features finales para el modelo.

Pool de no contactados (4,735 filas): contactos que aún no han recibido outreach, reservados para scoring en producción.

4.2 Fase 2: Análisis exploratorio (NB02)

El análisis exploratorio persigue dos objetivos: comprender la estructura de los datos y descubrir qué variables distinguen a los contactos que responden de los que no.

Distribución de la variable objetivo

El dataset presenta un desbalanceo moderado: 14.0% de positivos (841 respuestas) frente a 86.0% de negativos. Este ratio condiciona la elección de métricas en la Fase 4 — métricas como accuracy serían engañosas (un modelo que prediga siempre "no responde" acertaría el 86%), por lo que se priorizan métricas de ranking como PR-AUC, Precision@k y Lift.

Hallazgos principales

Seniority: Los VPs (19.6%) y Managers (16.2%) muestran tasas de respuesta superiores a los C-level (11.4%). El punto óptimo no es el cargo más alto, sino los decisores operativos de nivel medio-alto.

Tamaño de empresa: Las empresas medianas (200–2,000 empleados) con crecimiento de plantilla activo concentran las tasas de respuesta más altas. Empresas demasiado pequeñas (sin presupuesto) o demasiado grandes (procesos lentos) responden menos.

Canal de contacto: LinkedIn supera consistentemente a email en tasa de respuesta. El contexto profesional y personal de LinkedIn conecta mejor con prospectos B2B.

Timing: Los contactos que reciben el primer mensaje un jueves responden con mayor frecuencia. Lunes y viernes muestran el menor engagement, sugiriendo que el outreach a mitad de semana maximiza la probabilidad de respuesta.

Cualificación IA: El 25.5% de los contactos no tienen informe de contacto generado por IA (ai_CONTACT_REPORT), principalmente de campañas antiguas (v1.3) donde el proceso aún no existía. La tasa de respuesta en campañas con cualificación IA (~38%) es cinco veces superior a las campañas sin ella (~7%), lo que evidencia el impacto del proceso de enriquecimiento de Enginy.

Validación estadística

Los hallazgos se validaron con tests estadísticos formales para asegurar que los patrones observados no son producto del azar:

Test de Mann-Whitney: compara la distribución de cada variable numérica entre los contactos que responden y los que no. Por ejemplo, ¿tienen más conexiones en LinkedIn los que responden? Se utiliza este test — y no un t-test clásico — porque es no paramétrico: no asume distribución normal y es

robusto a outliers, ambas características presentes en nuestros datos. Si el p-valor es inferior a 0.05, la diferencia entre ambos grupos se considera estadísticamente significativa.

Test Chi-cuadrado: evalúa si existe asociación entre variables categóricas (seniority, tipo de contacto, FIT) y la variable objetivo. Compara las frecuencias observadas con las que se esperarían si no hubiera ninguna relación entre las variables. Por ejemplo, si los VPs responden mucho más de lo esperado por azar, el test lo detecta.

Corrección de Bonferroni: cuando se realizan múltiples tests simultáneamente (uno por cada feature), aumenta la probabilidad de encontrar resultados significativos por puro azar. Si se hacen 39 tests con un umbral del 5%, la probabilidad de al menos un falso positivo sube al 87%. La corrección de Bonferroni divide el umbral entre el número de tests (0.05 / 39 = 0.0013), controlando así la tasa de falsos positivos. En nuestro caso, los tests se realizaron sin esta corrección, pero los p-valores obtenidos son tan bajos (del orden de 10^{-17} en variables como número de conexiones) que los resultados serían significativos incluso con el umbral más conservador.

4.3 Fase 3: Ingeniería de features (NB03)

El objetivo de esta fase es transformar los datos brutos en variables predictivas que el modelo pueda aprovechar. Partimos de las 43 columnas del dataset de NB01 y generamos 31 features nuevas, alcanzando 70 columnas. De estas, se seleccionan las 39 features finales que alimentan el modelo.

Gestión de valores nulos y outliers

El dataset presenta nulos de naturaleza variada: columnas completamente vacías (Gender, Revenue, Jobs posted from LinkedIn), campos con cobertura insuficiente (<1%, como ai_FIT_IA) y variables parcialmente informadas (fe_company_age con 69.3% de cobertura, fe_headcount_momentum con 94.3%). En lugar de aplicar una estrategia única, se adoptó un tratamiento diferenciado según el tipo de variable y la causa del nulo:

Tipo	Estrategia	Justificación	Ejemplo
Columnas 100% vacías	Eliminación	No aportan información	Gender, Revenue
Columnas <1% cobertura	Eliminación	Insuficientes para generalizar	ai_FIT_IA (0.5%)
Nulos numéricos	Preservar como NaN	Imputación delegada al preprocesador (mediana)	fe_company_age (69.3%)
Nulos categóricos	Categoría "NULL" (valor 0)	Permite al modelo aprender el patrón de "desconocido"	fe_type_of_contact_ord
Nulos binarios	Valor por defecto (0)	Ausencia = ausencia del atributo	fe_has_email, fe_has_bio
Nulos en texto (NLP)	Cadena vacía o texto por defecto	Embeddings necesitan texto como entrada	nlp_report_length: fillna(0)
Outliers numéricos	Capping al percentil 1/99	Valores extremos distorsionan sin aportar señal	fe_headcount_momentum

¿Por qué no se eliminan registros con nulos?

Con un dataset de 5,987 contactos y solo 841 positivos (14%), cada registro con respuesta positiva es valioso. Eliminar filas con nulos reduciría la ya limitada clase positiva. En su lugar, se preservan los nulos y se delega la imputación al SimpleImputer(strategy="median") dentro del pipeline de sklearn, que se aplica justo antes del entrenamiento del modelo. Esto tiene tres ventajas:

Evita data leakage: la mediana se calcula solo sobre los datos de entrenamiento (fit), no sobre el dataset completo.

Consistencia train/test/producción: la misma mediana calculada en train se aplica como transform en test y en datos nuevos de producción. Por ejemplo, si la mediana de Number of connections en train es 656, un nulo en cualquier entorno se rellena siempre con 656.

Reproducibilidad: el imputer se serializa como parte del pipeline (preprocessor.pkl), garantizando que el comportamiento sea idéntico en cada ejecución.

Orígenes de las features

Origen	Prefijo	Cantidad	Ejemplos
Datos de LinkedIn/Raona	(ninguno)	9	Years in role, Number of employees
Ingeniería propia	fe_	14	fe_company_size_bucket, fe_headcount_momentum
Enriquecimiento externo	ext_	2	ext_ms_maturity_score, ext_has_competitor_tech
NLP sobre textos de IA	nlp_	8	nlp_embedding_01..03, nlp_topic
Tech fit por producto	fe_tech_fit_	7	fe_tech_fit_comunica, fe_tech_fit_ia

Features de ingeniería propia (fe_)

Estas variables se derivan de los datos existentes aplicando conocimiento del dominio:

Codificaciones ordinales: fe_seniority_ord transforma el seniority textual (JR, LEAD, MANAGER, DIRECTOR, CLEVEL) en valores numéricos ordenados. fe_type_of_contact_ord hace lo mismo con el tipo de contacto.

Transformaciones numéricas: fe_log_employees y fe_log_connections aplican transformación logarítmica para reducir el efecto de outliers. fe_company_age calcula la antigüedad de la empresa. fe_company_size_bucket discretiza el tamaño en cinco categorías.

Variables compuestas: fe_headcount_momentum combina el crecimiento de plantilla a 6 meses, 1 año y 2 años con pesos decrecientes (0.5, 0.3, 0.2), dando más importancia al crecimiento reciente.

Target encoding con suavizado bayesiano: fe_department_encoded codifica el departamento utilizando la tasa de respuesta de cada categoría, suavizada con la media global para evitar sobreajuste en categorías con pocos datos.

Features de enriquecimiento externo (ext_)

Estas variables se construyen a partir del campo Technologies used, que lista las tecnologías que usa cada empresa:

ext_ms_maturity_score: un score de madurez Microsoft que suma puntos por cada tecnología del ecosistema Microsoft detectada (Azure: +3, Microsoft 365: +2, Teams: +1, etc.) y resta por tecnologías competidoras (AWS: -1, Google Cloud: -1, Salesforce: -1).

ext_has_competitor_tech: flag binario que indica si la empresa usa tecnologías de competidores directos de Microsoft.

Estas features aportan contexto de dominio que no está en los datos de LinkedIn: una empresa con stack Microsoft avanzado es un prospecto más natural para Raona que una empresa con stack Google/AWS.

Features de NLP (nlp_)

Los campos de texto generados por la IA de Enginy (ai_COMPANY_REPORT, ai_CONTACT_REPORT, ai_MOMENTUM) contienen información rica pero no estructurada. Se procesaron con tres técnicas complementarias:

Sentence-BERT (modelo multilingual MiniLM): genera embeddings densos de 384 dimensiones a partir de los informes de empresa. Estos se reducen a 3 dimensiones con UMAP (nlp_embedding_01, nlp_embedding_02, nlp_embedding_03), capturando la similitud semántica entre empresas en un espacio compacto.

BERTopic aplica topic modeling sobre los embeddings para agrupar empresas por temática (nlp_topic). Identifica clústeres temáticos que revelan patrones en los tipos de empresa que responden.

Extracción de señales nlp_urgency_score cuenta palabras clave de urgencia (crecimiento, expansión, transformación digital, contratando, migración...) en los informes. nlp_has_momentum indica si el campo de momentum tiene contenido. nlp_report_length y nlp_contact_report_length capturan la longitud de los informes como proxy del nivel de enriquecimiento.

Features de tech fit por producto (fe_tech_fit_)

Raona ofrece siete líneas de producto (Comunica, Colabora, Infra, IA, Data, Workplace, MAITE). Para cada una se creó una variable binaria que detecta si la empresa del prospecto utiliza tecnologías relacionadas con ese producto. Por ejemplo, fe_tech_fit_comunica busca "Teams" o "Microsoft Teams" en el stack tecnológico, mientras que fe_tech_fit_ia busca "Copilot", "Azure AI" u "OpenAI".

Aplicación al pool de no contactados

Las mismas transformaciones se aplicaron al pool de 4,735 contactos no contactados, para que puedan ser scoreados en producción con el mismo modelo. Los embeddings y topics se generaron con los modelos UMAP y BERTopic ya entrenados sobre el dataset principal (transform, no fit), evitando data leakage.

4.4 Fase 4: Modelado predictivo (NB04)

Esta fase aborda la construcción del modelo de lead scoring, la segmentación de prospectos y la interpretación de resultados. Se estructura en tres bloques: selección y tuneo del modelo, análisis de importancia de features, y clustering.

Selección de features para el modelo

De las 70 columnas resultantes del feature engineering (Fase 3), se seleccionaron 39 features para alimentar el modelo. Se descartaron:

Columnas originales transformadas (ej: ai_SENIORITY se sustituye por fe_seniority_ord): incluir ambas introduciría redundancia y multicolinealidad.

Campos de texto bruto (ej: ai_COMPANY_REPORT): ya están representados por sus derivados NLP (embeddings, topics, longitud, urgencia).

Variables objetivo y auxiliares (target_replied, target_positive, _was_contacted, reply_message_number): no son features predictivas.

Columnas intermedias (ej: ai_TYPE_OF_CONTACT_clean, fe_department_corrected): pasos intermedios de la transformación, no variables finales.

Las 39 features seleccionadas representan la información no redundante del dataset: 9 variables originales de LinkedIn, 14 de ingeniería propia, 7 de tech fit por producto, 2 de enriquecimiento externo y 8 de NLP.

Elección de métricas

En un problema de ranking con clases desbalanceadas (14% positivos), las métricas clásicas de clasificación (accuracy, F1) son engañosas. Un modelo que prediga siempre "no responde" acertaría el 86%. Por ello se priorizaron métricas que evalúan la calidad del ranking:

Métrica	Qué mide	Por qué importa
PR-AUC	Área bajo la curva precision-recall	Métrica principal. Evalúa el rendimiento global en clases desbalanceadas
Precision@100	De los 100 mejores leads, ¿cuántos responden?	Simula el escenario real del equipo comercial
Lift@10%	Mejora vs selección aleatoria en el top 10%	Mide el valor añadido directo del modelo
ROC-AUC	Capacidad de separación entre clases	Métrica complementaria

Competición de modelos

Se evaluaron cuatro algoritmos de clasificación con validación cruzada estratificada (5 folds):

Modelo	PR-AUC	ROC-AUC	Observaciones
Logistic Regression	0.211	0.635	Baseline lineal, rápido

			pero limitado
Random Forest	0.256	0.654	Mejor que LR, prone a sobreajuste
LightGBM	0.278	0.668	Mejor rendimiento, seleccionado
XGBoost	0.271	0.662	Competitivo, ligeramente inferior

Tuneo de hiperparámetros con Optuna

Se realizaron 50 trials de optimización bayesiana con Optuna, maximizando PR-AUC en validación cruzada. Los hiperparámetros optimizados incluyen: learning rate, número de estimadores, profundidad máxima, número de hojas, regularización L1/L2 y scale_pos_weight para el desbalanceo de clases.

	PR-AUC	ROC-AUC
LightGBM (baseline)	0.278	0.668
LightGBM (tuneado)	0.303	0.676

Rendimiento final del modelo

Métrica	Valor	Interpretación
PR-AUC	0.303	Rendimiento sólido dado el desbalanceo
Precision@100	39%	39 responden de 100 (vs 14 aleatorio)
Lift@10%	2.6x	2.6 veces más respuestas que el azar
ROC-AUC	0.676	Capacidad de separación moderada-buena

Es importante contextualizar estas métricas: un PR-AUC de 0.303 puede parecer bajo en términos absolutos, pero en un problema donde la tasa base es 14% y las señales predictivas son sutiles (prospectos B2B similares entre sí), duplicar la precisión en los top leads tiene un impacto de negocio directo.

Análisis SHAP: qué aprendió el modelo

SHAP (SHapley Additive exPlanations) permite descomponer cada predicción en la contribución de cada feature. El análisis revela que los perfiles con mayor score comparten un patrón: managers y VPs en empresas medianas (200–2,000 empleados) con crecimiento de plantilla positivo y stack Microsoft existente.

Origen	Contribución SHAP	Interpretación
Datos raw (LinkedIn/Raona)	36.3%	Conexiones, años en puesto, tamaño empresa
Feature engineering	33.9%	Seniority, momentum de crecimiento, tamaño bucket
NLP	29.7%	Embeddings, topics, señales de

		urgencia
Enrichment externo	0.2%	Microsoft maturity score

Esto valida la estrategia de feature engineering: las features construidas (fe_ + nlp_) aportan el 63.6% de la capacidad predictiva del modelo, frente al 36.3% de los datos originales sin transformar.

Impacto del proceso de cualificación IA

Un hallazgo relevante es que nlp_contact_report_length — la longitud del informe de contacto generado por Enginy — actúa como proxy del proceso de cualificación IA. Los contactos con informe tienen una tasa de respuesta del ~38%, frente al ~7% de los que no lo tienen. Esta diferencia refleja la evolución de las campañas de Raona: las versiones recientes (v1.5/v1.6) incluyen cualificación IA sistemática, mientras que las antiguas (v1.3) no.

Target alternativo: respuestas positivas

Se evaluó target_positive (excluyendo respuestas negativas) como variable objetivo alternativa. El modelo rinde mejor con target_replied (PR-AUC 0.303 vs ~0.25), confirmando que la variable principal captura mejor la señal predictiva. Además, las respuestas negativas también generan valor comercial (referrals, follow-ups futuros).

Segmentación con K-Means

Para complementar el scoring con una visión estratégica, se aplicó K-Means clustering (k=4, silhouette=0.266) sobre variables de perfil empresarial:

Segmento	Perfil	Tasa respuesta	Tamaño
SMB Microsoft FIT+	PYME con Microsoft, FIT aprobado	11.9%	2,588
Enterprise Microsoft FIT+	Gran empresa con Microsoft	16.2%	1,234
Senior Non-FIT Responders	Alta seniority, sin FIT	17.4%	876
Non-Microsoft FIT+	FIT aprobado, sin Microsoft	13.6%	1,289

El segmento más revelador es "Senior Non-FIT Responders": tiene la mayor tasa de respuesta (17.4%) pero FIT aprobado = 0%. Esto sugiere que los criterios de cualificación de Enginy podrían estar descartando prospectos que realmente responden, una oportunidad para revisar las reglas de FIT.

4.5 Fase 5: MLOps — Infraestructura de producción (NB05)

Un modelo en un notebook no es un producto. Para que Raona pueda usar el lead scoring en su día a día, necesita una infraestructura que permita scorear nuevos contactos automáticamente, monitorizar la fiabilidad del modelo y reentrenar cuando sea necesario. Esta fase documenta el diseño y la implementación de esa infraestructura.

Dos entornos: demo y producción

El proyecto entrega dos entornos diferenciados que comparten los mismos artefactos del modelo:

	Demo (Streamlit Cloud)	Producción (propuesta)
Qué es	App interactiva ya desplegada	Arquitectura profesional propuesta
URL	raona-lead-scoring.streamlit.app	localhost:8000 (Docker local)
Scoring	Formulario individual + carga de CSV	API REST tiempo real + batch vía Airflow
Orquestación	Manual (el usuario sube datos)	Airflow DAGs automáticos
Monitorización	No	PSI mensual + reentrenamiento condicional
Estado	Desplegado y funcional	Código generado y probado localmente

Demo: Streamlit Cloud

La demo es una aplicación interactiva desplegada en Streamlit Cloud con tres pestañas: Dashboard (KPIs globales, distribución de scores, análisis por canal/timing y segmentación), Lead Scorer (formulario para scorear un contacto individual) y Batch Scorer (carga de CSV, scoring masivo y descarga del ranking en Excel). La app se despliega conectando Streamlit Cloud directamente al repositorio GitHub. Cada push a la rama main dispara una reconstrucción automática.

Arquitectura de producción

El sistema de producción se compone de dos bloques funcionales, desplegados en seis servicios Docker orquestados por docker-compose.yml:

Bloque	Servicio	Rol	Puerto
API	lead-scorer-api	Scoring REST en tiempo real	8000
Airflow	airflow-webserver	Interfaz web	8080
	airflow-scheduler	Ejecuta los DAGs programados	-
	airflow-triggerer	Triggers asíncronos	-
	airflow-init	Inicializa BD y usuario admin	-
	postgres	Base de datos de metadatos	5432

Cada bloque tiene su propio Dockerfile con dependencias específicas. El API necesita solo FastAPI y el modelo. Airflow necesita la plataforma completa más libgomp1 (OpenMP, requerido por LightGBM) y las dependencias de ML. En producción, Airflow se separa en servicios independientes por resiliencia (si el webserver cae, el scheduler sigue ejecutando DAGs), escalabilidad (cada servicio consume recursos diferentes) y mantenimiento (zero downtime en los pipelines).

Pipelines de producción

Módulo	Notebook origen	Función

ingest.py	NB01	Carga CSV de Enginy, valida esquema, crea target
transform.py	NB03	Feature engineering completo (39 features)
score.py	NB04	Scoring con lead_scorer.pkl + clustering
monitor.py	NB05	Calcula PSI por feature para detectar drift
retrain.py	NB05	Reentrena LightGBM con datos acumulados
validate.py	NB05	Compara candidato vs actual, promueve si es mejor

DAG 1: Scoring semanal

Se ejecuta cada vez que Raona exporta contactos nuevos de Enginy: ingest → transform → score → done. El resultado es un archivo con todos los contactos nuevos ordenados por lead_score descendente, con su cluster, nivel de prioridad y recomendaciones de canal y timing.

DAG 2: Monitoring mensual

Vigila si el modelo sigue siendo fiable: monitor → check_drift → [retrain → validate | skip] → done. La monitorización se basa en el PSI (Population Stability Index), que compara la distribución de cada feature entre los datos de entrenamiento y los datos más recientes. Si el PSI supera el umbral, el DAG reentrena un modelo candidato y lo compara con el actual. Solo lo promueve si mejora el PR-AUC en al menos 0.01.

Validación del entorno de producción

El sistema se probó localmente con docker compose up -d, verificando que los seis servicios arrancan correctamente, la API responde al health check y al scoring, y ambos DAGs se ejecutan con todos los tasks en estado success. La prueba se documentó con un vídeo demostrativo (https://youtu.be/aj558WhwrYM).

5. Resultados y Conclusiones

Resultados principales

El sistema de lead scoring demuestra que es posible priorizar el outreach B2B de forma significativamente más eficiente que la selección aleatoria:

Métrica	Valor	Impacto de negocio
PR-AUC	0.303	Rendimiento sólido en un problema con 14% de tasa base
Precision@100	39%	39 responden de 100 — frente a 14 con selección aleatoria
Lift@10%	2.6x	Multiplica por 2.6 la tasa de respuesta en el top 10%
Features	39	Combinación equilibrada: raw (36%), ingeniería (34%), NLP (30%)

Esto se traduce en un escenario concreto: si el equipo comercial de Raona contacta los 100 mejores leads según el modelo cada semana, obtendrá 39 respuestas en lugar de 14. Son 25 conversaciones adicionales por semana sin coste adicional de personal.

Hallazgos de negocio

1. El perfil óptimo no es el cargo más alto: VPs (19.6%) y Managers (16.2%) responden más que C-level (11.4%). El punto óptimo son los decisores operativos de nivel medio-alto, no los ejecutivos de máximo nivel.

2. La cualificación IA transforma los resultados: La introducción del proceso de enriquecimiento con IA de Enginy multiplicó por cinco la tasa de respuesta en las campañas recientes (~38% vs ~7% en campañas sin enriquecimiento). Esto valida la inversión de Raona en esta tecnología.

3. El segmento más valioso está siendo descartado: El clúster "Senior Non-FIT Responders" tiene la mayor tasa de respuesta (17.4%) pero FIT aprobado = 0%. Los criterios de cualificación de Enginy podrían estar descartando prospectos que realmente responden.

4. LinkedIn es el canal, jueves es el día: LinkedIn supera consistentemente a email en todos los segmentos. Los contactos que reciben el primer mensaje un jueves responden con mayor frecuencia.

Contribución técnica

Pipeline de NLP sobre textos de IA: El procesamiento de los informes generados por Enginy con Sentence-BERT, UMAP y BERTopic aporta el 30% de la capacidad predictiva del modelo, demostrando que los textos de cualificación IA contienen señal predictiva significativa.

Arquitectura de producción profesional: API REST con FastAPI, orquestación con Airflow (dos DAGs: scoring semanal y monitoring mensual), monitorización de drift con PSI, reentrenamiento condicional y despliegue en contenedores Docker con seis servicios.

Demo funcional: Aplicación Streamlit Cloud desplegada y accesible, con dashboard de KPIs, scoring individual y scoring en lote.

Limitaciones

1. Tamaño de la clase positiva: 841 respuestas de 5,987 contactos limitan la complejidad del modelo. Con más datos positivos, técnicas más sofisticadas podrían mejorar el rendimiento.

2. Embeddings NLP estáticos: los embeddings se generaron con un modelo preentrenado (MiniLM) sin fine-tuning sobre el dominio de Raona. Un modelo adaptado al vocabulario B2B/tecnológico podría capturar mejor las señales de los informes.

3. Features externas limitadas: las variables ext_ (maturity score, competitor tech) aportan solo el 0.2% de la importancia SHAP. Enriquecer con datos externos adicionales (INE, sector, digitalización) podría mejorar el perfilado de empresas.

Trabajo futuro

1. A/B testing — Validar el impacto real del modelo dividiendo al equipo comercial en dos grupos (con scoring vs sin scoring) durante 4-6 semanas para medir la diferencia en tasa de conversión.

2. Feedback loop — Incorporar los resultados del outreach en producción para reentrenar el modelo con datos más recientes, cerrando el ciclo de aprendizaje continuo.

3. Integración nativa con Enginy — Integrar la API de scoring directamente con la plataforma de outreach para que los scores aparezcan en la interfaz del vendedor sin exportar ni importar archivos.

Conclusión

Este proyecto demuestra que la aplicación de técnicas de machine learning al outreach B2B permite triplicar la precisión en la selección de leads prioritarios. El sistema construido — modelo predictivo, segmentación, pipeline NLP, infraestructura MLOps y demo interactiva — no es un ejercicio teórico: está probado con datos reales de producción, desplegado en Streamlit Cloud como demo funcional y validado localmente con Docker y Airflow como arquitectura de producción.

El equipo comercial de Raona puede usar el sistema hoy para contactar primero a los prospectos con mayor probabilidad de respuesta, optimizando su tiempo y multiplicando sus resultados.

6. Referencias / Bibliografía

Artículos académicos

Martínez-Salas, J. et al. (2025). The relevance of lead prioritization: a B2B lead scoring model based on machine learning. Frontiers in Artificial Intelligence, 8. https://www.frontiersin.org/journals/artificial-intelligence/articles/10.3389/frai.2025.1554325/full

Librerías y frameworks

Ke, G. et al. (2017). LightGBM: A Highly Efficient Gradient Boosting Decision Tree. NeurIPS. https://github.com/microsoft/LightGBM

Akiba, T. et al. (2019). Optuna: A Next-generation Hyperparameter Optimization Framework. KDD 2019. https://optuna.org

Lundberg, S. & Lee, S. (2017). A Unified Approach to Interpreting Model Predictions (SHAP). NeurIPS 2017. https://github.com/shap/shap

Reimers, N. & Gurevych, I. (2019). Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks. EMNLP 2019. https://www.sbert.net

Grootendorst, M. (2022). BERTopic: Neural topic modeling with a class-based TF-IDF procedure. https://github.com/MaartenGr/BERTopic

McInnes, L. et al. (2018). UMAP: Uniform Manifold Approximation and Projection for Dimension Reduction. https://github.com/lmcinnes/umap

Pedregosa, F. et al. (2011). Scikit-learn: Machine Learning in Python. JMLR, 12. https://scikit-learn.org

Plataformas y herramientas

Apache Airflow. https://airflow.apache.org

FastAPI. https://fastapi.tiangolo.com

Streamlit. https://streamlit.io

MLflow. https://mlflow.org

Docker. https://www.docker.com

Enginy (anteriormente Genesy AI). AI-Native Sales Platform for B2B. https://www.enginy.ai